

Министерство образования Республики Беларусь
Учреждение образования
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет компьютерных систем и сетей
Кафедра программного обеспечения информационных технологий
Дисциплина: Теория вероятностей и математическая статистика (ТВиМС)

ОТЧЕТ

по расчётной работе по статистике

Тема работы: Анализ дискретных и непрерывных
статистических данных

Выполнил
студент: гр. 051003

Феськов С.В.

Проверил:

Петюкевич Н.С.

Минск 2021

СОДЕРЖАНИЕ

1	Обозначения и используемые формулы	4
2	Анализ дискретных данных	6
2.1	Описание набора данных	6
2.2	Статистические законы распределения	7
2.2.1	Вариационный ряд:.....	7
2.2.2	Дискретный ряд распределения частот и частостей	7
2.2.3	Полигон относительных частот (частостей)	7
2.2.4	Эмпирическая функция распределения.....	8
2.3	Числовые характеристики статистических данных	9
2.3.1	Выборочное среднее (оценка мат. ожидания)	9
2.3.2	Мода	9
2.3.3	Медиана	9
2.3.4	Размах вариации.....	9
2.3.5	Среднее линейное отклонение	9
2.3.6	Выборочные дисперсия и среднеквадратичное отклонение	9
2.3.7	Асимметрия	9
2.3.8	Эксцесс.....	9
2.3.9	Коэффициент вариации.....	9
2.4	Анализ статистических законов распределения и числовых характеристик	10
2.4.1	Близость оценок математического ожидания, моды и медианы .	10
2.4.2	Близость оценки дисперсии к нулю	10
2.4.3	Анализ значения коэффициента вариации.....	10
2.4.4	Анализ асимметрии	10
2.4.5	Анализ эксцесса	10
2.4.6	Соотношение между оценкой математического ожидания и дисперсией.....	11
2.4.7	Общий вывод.....	11
3	Проверка гипотезы о виде распределения дискретных данных	12
3.1	Выдвижение гипотезы	12
3.2	Расчёт теоретических законов распределения и графический анализ ..	13
3.2.1	Функция вероятности	13
3.2.2	Теоретические частоты	13
3.2.3	Полигоны статистической и теоретической частостей	14
3.2.4	Графики функций распределения	15
3.2.5	Анализ графиков	15
3.2.6	Проверка	15
3.3	Проверка гипотезы о виде распределения.....	16
3.3.1	По критерию согласия Пирсона	16
3.3.2	По критерию согласия Романовского	17
3.3.3	По критерию согласия Ястремского	17
4	Анализ непрерывных данных	18

4.1	Описание набора данных	18
4.1	Статистические законы распределения	19
4.1.1	Вариационный ряд:.....	19
4.1.2	Интервальный ряд распределения частот и частостей	19
4.1.3	Гистограмма относительных частот (частостей)	19
4.1.4	Эмпирическая функция распределения.....	20
4.2	Числовые характеристики статистических данных	21
4.2.1	Выборочное среднее (оценка мат. ожидания)	21
4.2.2	Мода	21
4.2.3	Медиана	21
4.2.4	Размах вариации.....	21
4.2.5	Среднее линейное отклонение	21
4.2.6	Выборочные дисперсия и среднеквадратичное отклонение	21
4.2.7	Асимметрия	21
4.2.8	Эксцесс.....	21
4.2.9	Коэффициент вариации.....	21
4.3	Анализ статистических законов распределения и числовых характеристик	22
4.3.1	Близость оценок математического ожидания, моды и медианы .	22
4.3.2	Близость оценки дисперсии к нулю	22
4.3.3	Анализ значения коэффициента вариации.....	22
4.3.4	Анализ асимметрии	22
4.3.5	Анализ эксцесса	22
4.4	Анализ использования правила сложения дисперсий.....	23
4.4.1	Результаты расчётов	23
4.4.2	Анализ результатов.....	23
5	Проверка гипотезы о виде распределения Непрерывных данных.....	24
5.1	Выдвижение гипотезы	24
5.2	Расчёт теоретических законов распределения и графический анализ ..	25
5.2.1	Плотность распределения	25
5.2.2	Функция распределения.....	25
5.2.3	Теоретические частоты	25
5.2.4	Гистограмма статистических частостей и плотность равномерного распределения	26
5.2.5	Графики функций распределения	26
5.2.6	Анализ графиков	26
5.2.7	Проверка	27
5.3	Проверка гипотезы о виде распределения.....	28
5.3.1	По критерию согласия Пирсона	28
5.3.2	По критерию согласия Романовского	28
5.3.3	По критерию согласия Ястремского	28

1 ОБОЗНАЧЕНИЯ И ИСПОЛЬЗУЕМЫЕ ФОРМУЛЫ

x_i – варианта

n_i – частота варианты или интервала

ω_i – частотность варианты или интервала

$F(x)$ – функция распределения

k – количество вариант

$$\bar{x} = \frac{\sum_{i=1}^k x_i * n_i}{\sum_{i=1}^k n_i} - \text{выборочное среднее}$$

$$M_0 = x_n + h \frac{n_{\text{мод}} - n_{\text{пред}}}{(n_{\text{мод}} - n_{\text{пред}}) + (n_{\text{мод}} - n_{\text{пост}})} - \text{мода (формула только для интервальных рядов)}$$

n_1, n_2, n_3 – частоты предмодального, модального и постмодального интервалов

x_n – значение левой границы модального интервала

$$M_e = x_n + h \frac{\frac{\sum_{i=1}^k n_i}{2} - \sum_{i=1}^{k_{M_e}} n_i}{n_{M_e}} - \text{медиана (формула только для интервальных рядов)}$$

x_n – значение левой границы медианного интервала

$$R = x_{\max} - x_{\min} - \text{размах вариации}$$

$$l = \frac{\sum_{i=1}^k |x_i - \bar{x}| * n_i}{\sum_{i=1}^k n_i} - \text{среднее линейное отклонение}$$

$$\bar{D} = \frac{\sum_{i=1}^k (x_i - \bar{x})^2 * n_i}{\sum_{i=1}^k n_i} - \text{выборочная дисперсия}$$

$$\bar{\sigma} = \sqrt{\bar{D}} - \text{выборочное среднеквадратичное отклонение}$$

$$V = \frac{\bar{\sigma}}{\bar{x}} - \text{коэффициент вариации}$$

$$\mu_m = \frac{\sum_{i=1}^k (x_i - \bar{x})^m * n_i}{\sum_{i=1}^k n_i} - \text{центральный момент } m - \text{го порядка}$$

$$S_x = \frac{\mu_3}{\sigma^3} - \text{асимметрия}$$

$$\varepsilon_x = \frac{\mu_4}{\sigma^4} - 3 - \text{эксцесс}$$

$$\sigma_j^2 = \frac{\sum_{i=1}^{k_{\text{в группе}}} (x_i - \bar{x}_j)^2 * n_i}{\sum_{i=1}^{k_{\text{в группе}}} n_i} - \text{групповая дисперсия}$$

$$\bar{\sigma}^2 = \frac{\sum_{i=1}^{k_{\text{групп}}} \sigma_i^2 n_i}{\sum_{i=1}^{k_{\text{групп}}} n_i} - \text{средняя групповая дисперсия}$$

$$\delta^2 = \frac{\sum_{i=1}^{k_{\text{групп}}} (\bar{x}_i - \bar{x})^2 * n_i}{\sum_{i=1}^{k_{\text{групп}}} n_i} - \text{межгрупповая дисперсия}$$

$$p(x) = P(X = x) - \text{функция вероятности}$$

$$p_i - \text{вероятность попасть в интервал } i$$

$$\chi^2 = \sum_{i=1}^{k_{\text{интервалов}}} \frac{(n_i - np_i)^2}{np_i} - \text{критерий согласия Пирсона}$$

$$R = \frac{|\chi^2 - k|}{\sqrt{2k}} - \text{критерий Романовского } (k - \text{число степеней свободы})$$

$$J = \frac{|\chi^2 - k|}{\sqrt{2n + 2.4}} - \text{критерий Ястремского } (n - \text{число интервалов})$$

Все расчёты были проведены в Python с использованием библиотек math, pandas и numpy. Графики построены в Python с помощью библиотеки matplotlib. Код исходников вычисления - code.docx, построения графиков - graphic.docx.

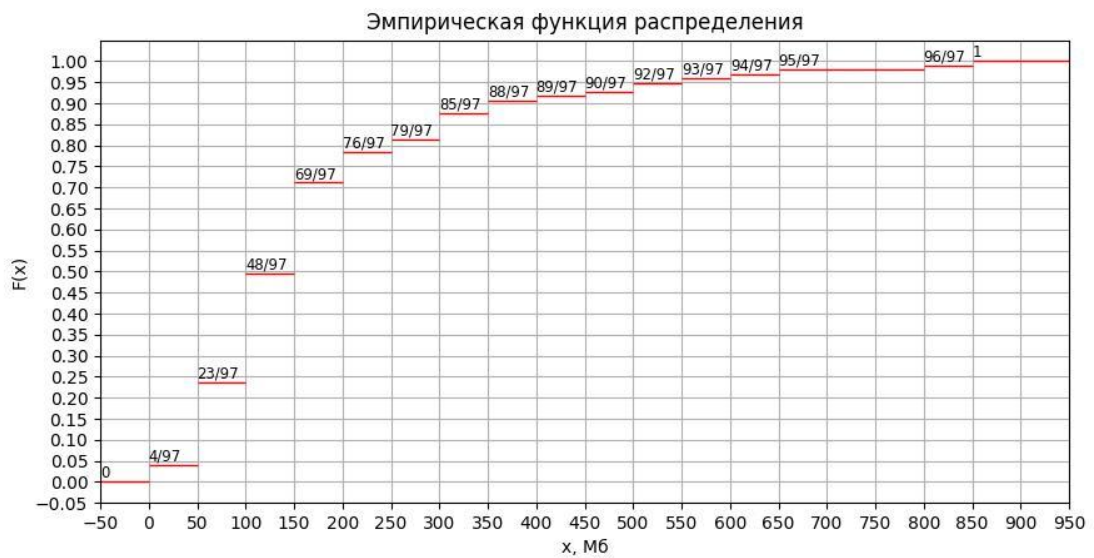
2 АНАЛИЗ ДИСКРЕТНЫХ ДАННЫХ

2.1 Описание набора данных

Каждый элемент из набора представляет собой количество потраченных мобильных данных на приложение «VK» в течение дня и округлённое до 50 Мб. Набор данных состоит из 101-го элемента, каждый из которых соответствует одному дню с 1 сентября по 10 декабря. С 24 по 27 сентября данные отсутствуют (фактически данные равны нулю, но они не учитываются, так как в этом промежутке мобильный интернет у меня в принципе отсутствовал), поэтому «очищенный» набор состоит из 97 элементов.

2.2.4 Эмпирическая функция распределения

$$F(x) = \begin{cases} 0, & x \leq 0 \\ 4/97, & 0 < x \leq 50 \\ 23/97, & 50 < x \leq 100 \\ 48/97, & 100 < x \leq 150 \\ 69/97, & 150 < x \leq 200 \\ 76/97, & 200 < x \leq 250 \\ 79/97, & 250 < x \leq 300 \\ 85/97, & 300 \leq x < 350 \\ 88/97, & 350 \leq x < 400 \\ 89/97, & 400 \leq x < 450 \\ 90/97, & 450 \leq x < 500 \\ 92/97, & 500 \leq x < 550 \\ 93/97, & 550 \leq x < 600 \\ 94/97, & 600 \leq x < 650 \\ 95/97, & 650 \leq x < 800 \\ 96/97, & 800 \leq x < 850 \\ 1, & x > 850 \end{cases}$$



2.3 Числовые характеристики статистических данных

2.3.1 Выборочное среднее (оценка мат. ожидания)

$$\bar{x} = 174.22680412371133$$

2.3.2 Мода

$$M_0 = 100$$
$$\omega_{M_0} = \frac{25}{97}$$

2.3.3 Медиана

$$M_e = 125$$
$$F(M_e) = \frac{48}{97} \approx \frac{1}{2}$$

2.3.4 Размах вариации

$$R = 850$$

2.3.5 Среднее линейное отклонение

$$l = 111.78658731002233$$

2.3.6 Выборочные дисперсия и среднеквадратичное отклонение

$$\bar{D} = 25882.13412689978$$
$$\bar{\sigma} = 160.87925325193356$$

2.3.7 Асимметрия

$$S_x = 2.116317340851388$$

2.3.8 Эксцесс

$$\varepsilon_x = -1.5603414166897873$$

2.3.9 Коэффициент вариации

$$V = 0.923389796771453$$

2.4 Анализ статистических законов распределения и числовых характеристик

2.4.1 Близость оценок математического ожидания, моды и медианы

Мода и медиана достаточно близки друг к другу, а учитывая то, что медиана в распределении ДСВ рассчитывается неточно (так как функция распределения прерывна и она может не принимать значения $\frac{1}{2}$), можно считать их равными. Однако значение выборочного среднего достаточно далеко от значений моды и медианы, что говорит о наличии некоторой асимметрии в этом распределении, которая к тому же видна на полигоне этих данных.

Проверим соотношение $|M_0 - \bar{x}| \cong 3|M_e - \bar{x}|$:

$$|M_0 - \bar{x}| = 49.226$$

$$3|M_e - \bar{x}| = 74.226$$

Соотношение не выполнено, поэтому данный статистический ряд нельзя назвать умеренно асимметричным.

2.4.2 Близость оценки дисперсии к нулю

Выборочная дисперсия значительно удалена от нуля, что связано с в принципе большими значениями данных в выборке и наличием слишком больших единичных значений данных, сильно влияющих на дисперсию, хоть их частота и минимальна.

2.4.3 Анализ значения коэффициента вариации

Коэффициент вариации V практически равен единице, что говорит о достаточно большом разбросе данных и высокой степени их случайности.

2.4.4 Анализ асимметрии

Асимметрия чуть больше 2, что говорит о достаточно высокой степени положительной асимметрии, вызванной наличием единичных значений данных справа от мат. ожидания и отсутствием таких единичных данных слева от него.

2.4.5 Анализ эксцесса

Эксцесс приблизительно равен -1.5, что указывает на плосковершие распределения относительно нормального распределения.

2.4.6 Соотношение между оценкой математического ожидания и дисперсией

Отношение выборочной дисперсии к выборочному мат. ожиданию приблизительно равно 150, что даёт нам основание усомниться в рассмотрении таких теоретических распределений ДСВ как распределение Пуассона (в котором $m = D$) и биномиальное распределение (в котором $D = m * q$, где $0 \leq q \leq 1$).

2.4.7 Общий вывод

Положительной асимметрии, такого большого значения дисперсии и коэффициента вариации и отличия выборочного среднего от моды и медианы можно было избежать, если бы мы убрали из рассмотрения данные со слишком большими значениями, однако тогда бы выборка стала намного меньше.

3 ПРОВЕРКА ГИПОТЕЗЫ О ВИДЕ РАСПРЕДЕЛЕНИЯ ДИСКРЕТНЫХ ДАННЫХ

3.1 Выдвижение гипотезы

Для этих данных, исходя из их анализа, хорошо не подходит ни одно из дискретных теоретических распределений, так как:

1. Отношение дисперсии к мат. ожиданию, равное приблизительно 150, не соответствует теоретическим соотношениям дисперсии и мат. ожидания в распределении Пуассона ($D/m = 1$) и в биномиальном распределении ($D/m = q \leq 1$);
2. Вид полигона частостей и вид эмпирической функции распределения не соответствует теоретическому виду для геометрического распределения (в котором кривая распределения сразу убывает с 0 на полигоне).

И хоть для геометрического распределения соотношение выборочных дисперсии и мат. ожидания приемлемы, всё-таки графически оно будет меньше сходиться с выборкой чем распределение Пуассона, поэтому ядвигаю гипотезу о том, что данные имеют распределение Пуассона.

3.2 Расчёт теоретических законов распределения и графический анализ

Так как собранные данные содержатся в диапазоне от 0 до 850 Мб с шагом 50 Мб, а случайная величина в распределение Пуассона – от 0 и далее с шагом 1, то для расчёта законов распределения Пуассона необходимо нормализовать значения случайной величины: поделить на 50. Т. о. мы будем рассчитывать значения законов распределения Пуассона в диапазоне от 0 до 17 с шагом 1 ($850/50 = 17$)

Вместо исходного выборочного среднего (равного ≈ 174) как оценку мат. ожидания рассмотрим нормализованное выборочное среднее ($\frac{\bar{x}}{50} \approx 3.48$) и нормализованную медиану ($\frac{M_e}{50} = 2.5$).

3.2.1 Функция вероятности

$$p(k) = \frac{e^{-\lambda} \lambda^k}{k!},$$

где $\lambda = m$ – параметр распределения Пуассона.

3.2.2 Теоретические частоты


(при $m = 2.5$)

	х	к	р
х1(к1)	0	0	8.30e-02
х2(к2)	50	1	2.07e-01
х3(к3)	100	2	2.57e-01
х4(к4)	150	3	2.13e-01
х5(к5)	200	4	1.33e-01
х6(к6)	250	5	6.61e-02
х7(к7)	300	6	2.74e-02
х8(к8)	350	7	9.74e-03
х9(к9)	400	8	3.03e-03
х10(к10)	450	9	8.38e-04
х11(к11)	500	10	2.09e-04
х12(к12)	550	11	4.72e-05
х13(к13)	600	12	9.79e-06
х14(к14)	650	13	1.87e-06
х15(к15)	700	14	3.33e-07
х16(к16)	750	15	5.53e-08
х17(к17)	800	16	8.60e-09
х18(к18)	850	17	1.26e-09

(при $m = 3.48$)

	х	к	р
х1(к1)	0	0	3.07e-02
х2(к2)	50	1	1.07e-01
х3(к3)	100	2	1.86e-01
х4(к4)	150	3	2.16e-01
х5(к5)	200	4	1.88e-01
х6(к6)	250	5	1.31e-01
х7(к7)	300	6	7.62e-02
х8(к8)	350	7	3.80e-02
х9(к9)	400	8	1.65e-02
х10(к10)	450	9	6.40e-03
х11(к11)	500	10	2.23e-03
х12(к12)	550	11	7.07e-04
х13(к13)	600	12	2.05e-04
х14(к14)	650	13	5.50e-05
х15(к15)	700	14	1.37e-05
х16(к16)	750	15	3.18e-06
х17(к17)	800	16	6.92e-07
х18(к18)	850	17	1.42e-07

3.2.3 Полигоны статистической и теоретической частот




(при $m = 2.5$)

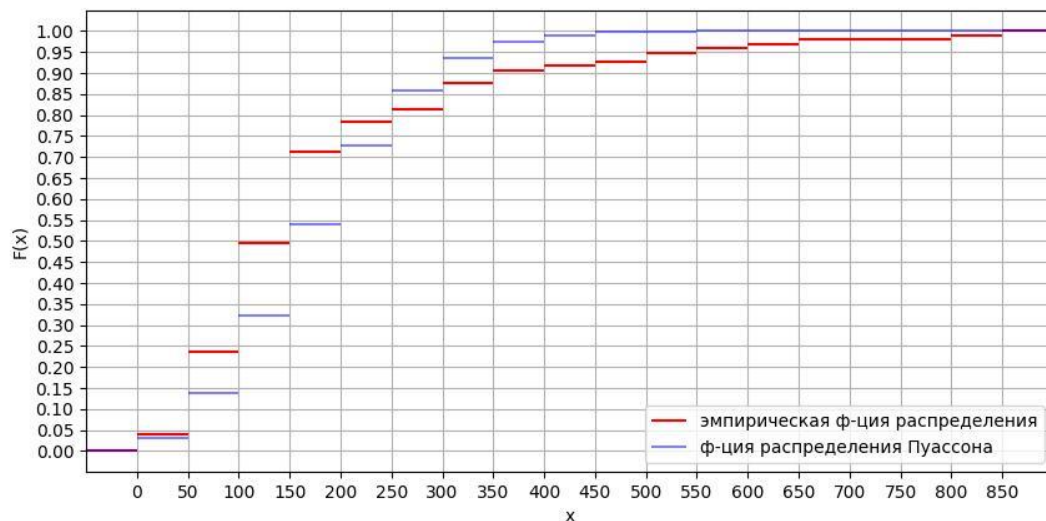


(при $m = 3.48$)

3.2.4 Графики функций распределения



(при $m = 2.5$)



(при $m = 3.48$)

3.2.5 Анализ графиков

Как мы видим по полигонам, и при $m = 3.48$, и при $m = 2.5$, распределение Пуассона соответствует статистике, однако при $m = 2.5$ соответствие практически полное. На графиках функций распределения расхождения есть, но общая статистическая тенденция совпадает с теоретическим распределением.

$$3.2.6 \text{ Проверка } \left| 1 - \sum_{j=1}^M p_i \right| \leq 0,01.$$

$$\left| 1 - \sum_{j=1}^M p_i \right| = 2.0e-10 \ll 0,01$$

3.3 Проверка гипотезы о виде распределения

При расчёте критериев вариационный ряд был разбит на интервалы так, чтобы в каждом интервале частота была не меньше 5:

	i1	i2	i3	i4	i5	i6	i7
i_i	0-50	100	150	200	250-300	350-450	500-850
n_i	23	25	21	7	9	5	7
p_i ($m=2.5$)	2.90e-01	2.57e-01	2.13e-01	1.33e-01	9.35e-02	1.36e-02	2.68e-04
p_i ($m=3.48$)	1.38e-01	1.86e-01	2.16e-01	1.88e-01	2.08e-01	6.09e-02	3.21e-03

(здесь i_i – интервал с номером i)

3.3.1 По критерию согласия Пирсона

При $m = 2.5$:

$$\chi^2 = 1885.096$$

При $m = 3.48$:

$$\chi^2 = 166.359$$

Как мы видим, более подходящее графически распределение Пуассона с $m = 2.5$, намного меньше подходит с точки зрения критерия Пирсона, что связано, по моему мнению, с недостаточно большой выборкой (так как в нашей выборке значения, вероятность которых теоретически должна быть близка к нулю, в выборке имеют достаточно большой вес).

Однако и при $m = 3.48$ критерий плох, так как его критическое значение при $\alpha = 0.05$ и $k = 7 - 1 - 1 = 5$ равно $\chi_{0.05,5}^2 = 11.07$, что намного меньше, чем рассчитанные значения.


Но видна закономерность, что при увеличении m , критерий Пирсона уменьшается, поэтому можно попробовать подобрать наиболее подходящий m :

$$\text{При } m = 4 \quad \chi^2 = 100.221;$$

$$\text{При } m = 4.1 \quad \chi^2 = 98.609;$$

$$\text{При } m = 4.2 \quad \chi^2 = 99.338.$$

Как мы видим, лучшее значение критерия получается при $m = 4.1$, однако график при таком m выглядит следующим образом:



Т. о. при всех возможных m данную гипотезу следует отвергнуть.

3.3.2 По критерию согласия Романовского

При $m = 2.5$:

$$R = 594.538$$

При $m = 3.48$:

$$R = 51.026$$

При $m = 4.1$:

$$R = 29.601$$

Как мы видим, ни при каком m полученный критерий R не меньше 3, значит во всех случаях данную гипотезу следует отвергнуть.

3.3.3 По критерию согласия Ястремского

При $m = 2.5$:

$$J = 464.256$$

При $m = 3.48$:

$$J = 39.844$$

При $m = 4.1$:

$$J = 23.115$$

Как мы видим, ни при каком m полученный критерий R не меньше 3, значит во всех случаях данную гипотезу следует отвергнуть.

4 АНАЛИЗ НЕПРЕРЫВНЫХ ДАННЫХ

4.1 Описание набора данных

Каждый элемент из набора представляет собой курс биткойна к доллару в определённый день. Набор данных состоит из 101-го элемента, каждый из которых соответствует одному дню с 1 сентября по 10 декабря. Данные были взяты с сайта <https://www.rbc.ru/crypto/currency/btcusd>.

4.1 Статистические законы распределения


4.1.1 Вариационный ряд:

{40369.0, 40950.0, 41124.4, 42161.4, 42560.0, 42721.85, 42750.75, 43150.4, 43621.55, 43873.15, 44770.25, 44864.15, 44959.0, 45103.7, 46042.55, 46067.75, 46358.5, 46549.85, 47005.15, 47079.85, 47249.15, 47300.0, 47550.0, 47733.9, 47815.75, 48076.45, 48138.9, 48145.75, 48241.95, 48900.0, 49096.6, 49108.25, 49350.0, 49354.75, 49879.1, 49909.07, 50554.1, 50589.6, 50600.0, 51615.75, 51746.35, 52728.9, 53560.0, 53790.9, 53810.05, 53991.0, 54400.0, 54669.8, 55034.3, 55498.6, 56120.8, 56321.2, 56838.55, 56922.75, 57049.25, 57101.5, 57216.75, 57225.65, 57232.15, 57285.0, 57543.25, 57689.95, 57800.0, 58116.05, 58538.55, 58600.0, 58965.75, 59849.0, 60250.0, 60383.55, 60389.5, 60565.55, 60829.35, 60860.5, 60872.45, 61088.35, 61100.75, 61255.85, 61296.3, 61376.8, 61516.1, 61592.7, 61700.0, 61820.0, 62021.1, 62090.45, 62255.75, 62979.35, 63000.0, 63215.25, 63250.0, 63500.0, 64250.0, 64269.15, 64489.75, 64828.85, 64940.05, 65434.8, 66016.9, 66897.25, 67530.7}

4.1.2 Интервальный ряд распределения частот и частостей

	a1-a2	a2-a3	a3-a4	a4-a5	a5-a6	a6-a7	a7-a8	a8-a9
$a_i - a_{i+1}$	40369-43769	43769-47169	47169-50569	50569-53969	53969-57369	57369-60769	60769-64169	64169-67569
n_i	9	11	17	8	15	12	20	9
ω_i	9/101	11/101	17/101	8/101	15/101	12/101	20/101	9/101

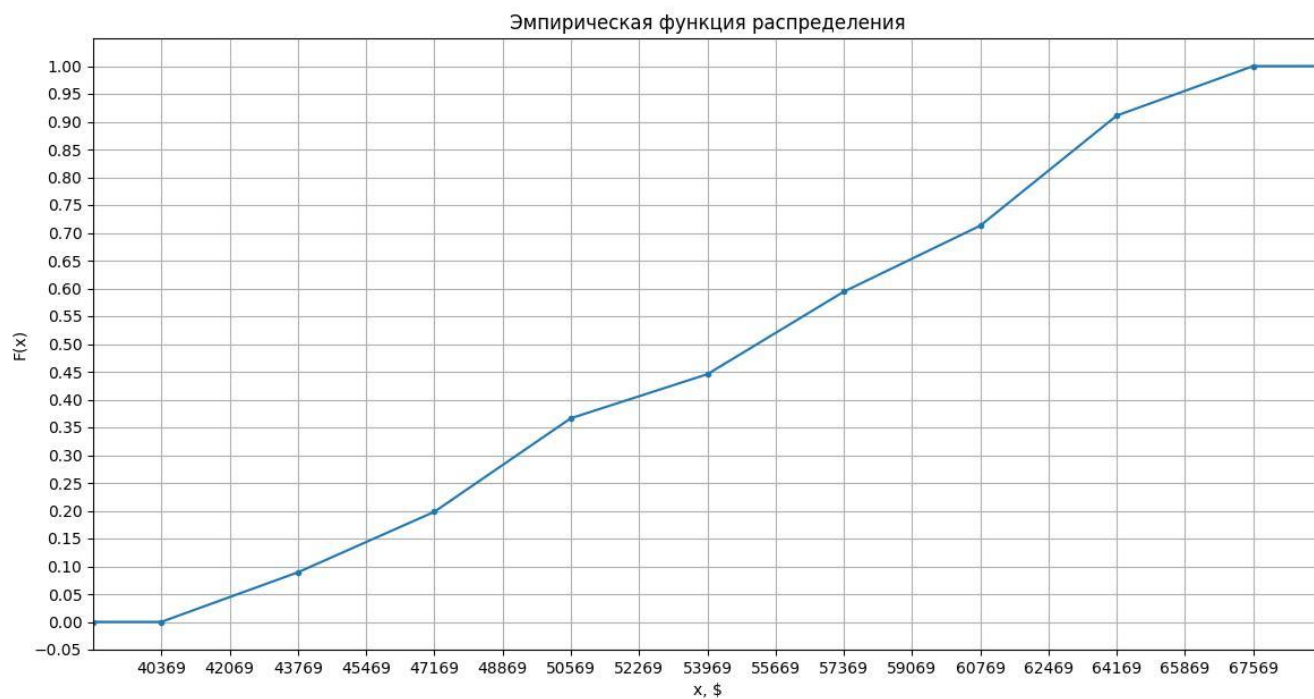
4.1.3 Гистограмма относительных частот (частостей)



4.1.4 Эмпирическая функция распределения

$$F(x) = \begin{cases} 0, & x \leq 40369 \\ \sum_{i=1}^{k-1} \omega_i, & 40369 < x \leq 65869 \\ 1, & x > 65869 \end{cases}$$

(k — номер интервала, в котором находится x)



4.2 Числовые характеристики статистических данных

4.2.1 Выборочное среднее (оценка мат. ожидания)

$$\bar{x} = 54503.02445544554$$

4.2.2 Мода

$i = 7$ (номер модального интервала)

$$M_0 = 62200.57894736842$$

$$\omega_{M_0} = \frac{20}{101}$$

4.2.3 Медиана

$i = 5$ (номер медианного интервала)

$$M_e = 55215.67$$

4.2.4 Размах вариации

$$R = 27161.7$$

4.2.5 Среднее линейное отклонение

$$l = 6461.834245662185$$

4.2.6 Выборочные дисперсия и среднеквадратичное отклонение

$$\bar{D} = 53591626.78816333$$

$$\bar{\sigma} = 7320.630217963705$$

4.2.7 Асимметрия

$$S_x = -0.17976445456751847$$

4.2.8 Эксцесс

$$\varepsilon_x = -1.2039011647433924$$

4.2.9 Коэффициент вариации

$$V = 0.13431603642377835$$

4.3 Анализ статистических законов распределения и числовых характеристик

4.3.1 Близость оценок математического ожидания, моды и медианы

Выборочное среднее и медиана практически равны и находятся в центре диапазона значений вариационного ряда, но они сильно отличаются от моды. Это говорит о том, что ряд не обладает абсолютной симметрией, однако ряд вполне может быть приближённо симметричным. Данные соотношения между выборочным средним, модой и медианой наводят на мысль о том, что этому вариационному ряду может соответствовать равномерное распределение и скорее всего не соответствует нормальное и экспоненциальное распределения.

4.3.2 Близость оценки дисперсии к нулю

Выборочная дисперсия значительно удалена от нуля, что связано с большими значениями данных в выборке.

4.3.3 Анализ значения коэффициента вариации

Коэффициент вариации V практически равен 0.13, что говорит о возможном маленьком разбросе случайной величины относительно мат. ожидания.

4.3.4 Анализ асимметрии

Асимметрия примерно равна -0.2, значит ряд достаточно симметричен (обладает небольшой отрицательной асимметрией).

4.3.5 Анализ эксцесса

Эксцесс приблизительно равен -1.2, что указывает на плосковерхие распределения относительно нормального распределения.

4.4 Анализ использования правила сложения дисперсий

4.4.1 Результаты расчётов

Интервалы	Групповые средние	Групповые дисперсии
40369-43769	42156,59444	1076203,054
43769-47169	45697,62727	983718,5774
47169-50569	48611,98353	923331,6152
50569-53969	52305,19375	1608070,971
53969-57369	56193,82	1274982,618
57369-60769	59057,59583	1247765,802
60769-64169	61881,0525	728965,6959
64169-67569	65406,38333	1236743,677

$$\bar{\sigma}^2 = 1077978.9402740872$$

$$\delta^2 = 52513647.84788923$$

$$\eta^2 = 0.97988$$

4.4.2 Анализ результатов

$$\bar{\sigma}^2 + \delta^2 = 53591626.78816$$

$$\bar{D} = 53591626.78816$$

Соотношение $\bar{\sigma}^2 + \delta^2 = \bar{D}$ выполняется, а значит теорема сложения дисперсий верна.

Эмпирический коэффициент детерминации практически равен 1, значит доля значимости группировки максимальна, то есть выполненная группировка является хорошей.

5 ПРОВЕРКА ГИПОТЕЗЫ О ВИДЕ РАСПРЕДЕЛЕНИЯ НЕПРЕРЫВНЫХ ДАННЫХ

5.1 Выдвижение гипотезы

Учитывая то, что интервальный ряд имеет несколько максимумов (что видно из графика гистограммы), а медиана и выборочное среднее совпадают и находятся в центре диапазона значений данных (но при этом мода находится в отдалении от медианы и выборочного среднего), можно достаточно точно отбросить из рассмотрения нормальное и показательное распределение и выдвинуть гипотезу о том, что данные имеют равномерное распределение.

5.2 Расчёт теоретических законов распределения и графический анализ

Параметры равномерного распределения a и b рассчитаем как границы диапазона значений данных, то есть:

$$a = 40369$$

$$b = 67530.7$$

5.2.1 Плотность распределения

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & x < a \cup x > b \end{cases}$$

5.2.2 Функция распределения

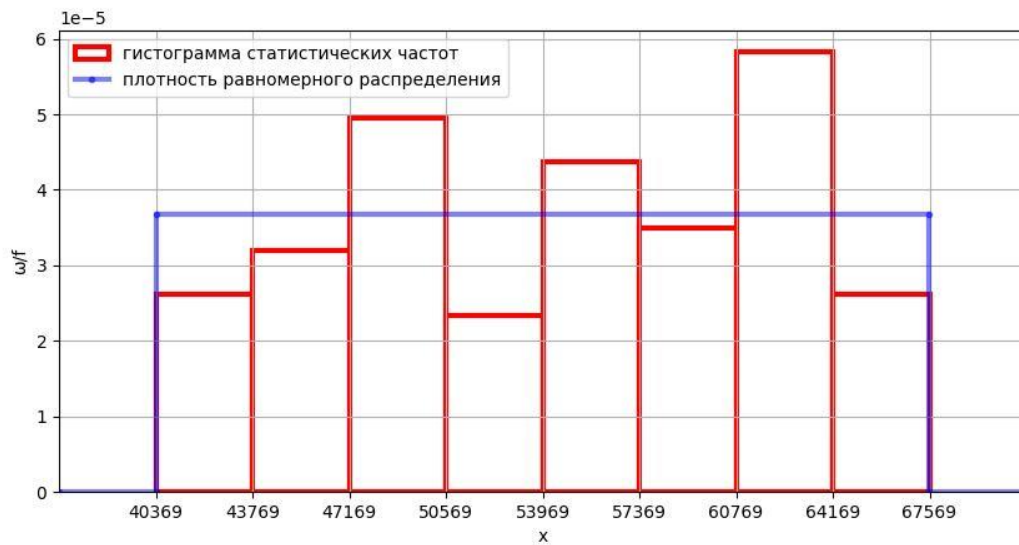
$$F(x) = \begin{cases} 0, & x < a \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & x > b \end{cases}$$

5.2.3 Теоретические частоты

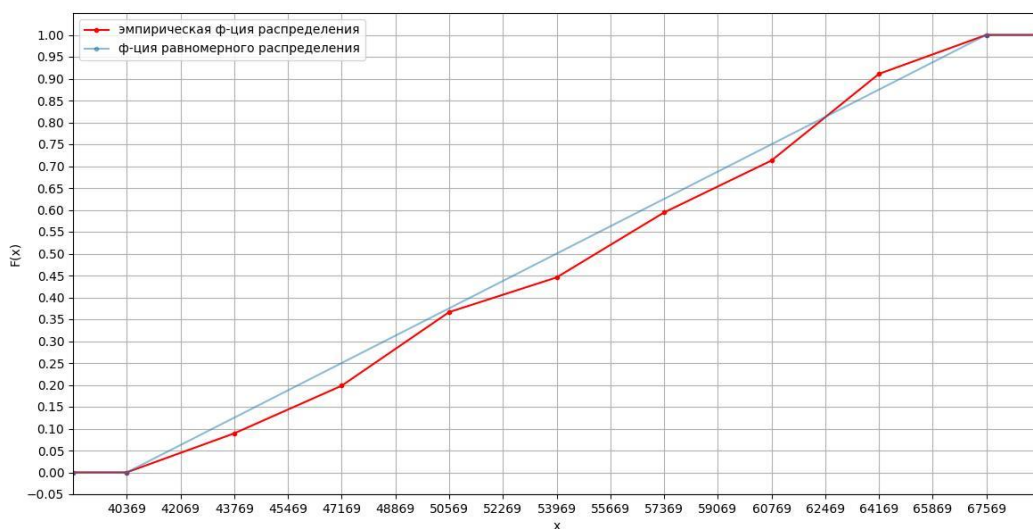
Вероятность попасть в интервал $a_i - a_{i+1}$ будем рассчитывать по формуле $p_i = F(a_{i+1}) - F(a_i)$.

	$a_i - a_{i+1}$	n_i	ω_i	p_i
a0-a1	40369.0-43769.0	9	9/101	1.25e-01
a1-a2	43769.0-47169.0	11	11/101	1.25e-01
a2-a3	47169.0-50569.0	17	17/101	1.25e-01
a3-a4	50569.0-53969.0	8	8/101	1.25e-01
a4-a5	53969.0-57369.0	15	15/101	1.25e-01
a5-a6	57369.0-60769.0	12	12/101	1.25e-01
a6-a7	60769.0-64169.0	20	20/101	1.25e-01
a7-a8	64169.0-67569.0	9	9/101	1.24e-01

5.2.4 Гистограмма статистических частот и плотность равномерного распределения



5.2.5 Графики функций распределения



5.2.6 Анализ графиков

Гистограмма и функция распределения достаточно сильно отличаются, хоть функция распределения и описывает общую тенденцию распределения как у гистограммы. А вот функции распределения достаточно похожи

$$5.2.7 \text{ Проверка } \left| 1 - \sum_{j=1}^M p_i \right| \leq 0,01.$$

$$\left| 1 - \sum_{j=1}^M p_i \right| = 0 \ll 0,01$$

5.3 Проверка гипотезы о виде распределения

При расчёте χ^2 будем использовать существующие интервалы, так как они все удовлетворяют необходимым условиям (частота для каждого интервала больше 4).

$$\chi^2 = 10.203$$

5.3.1 По критерию согласия Пирсона

$$\alpha = 0.05$$

$$k = 8 - 1 - 2 = 5$$

Для данных k и α критическое значение критерия согласия Пирсона равно $\chi^2_{0.05,5} = 11.07$.

Как видно, $\chi^2 < \chi^2_{0.05,5}$, значит гипотеза о равномерном виде распределения принимается.

5.3.2 По критерию согласия Романовского

$$R = 1.645$$

$R < 3$, значит гипотеза принимается.

5.3.3 По критерию согласия Ястремского

$$J = 1.213$$

$J < 3$, значит гипотеза принимается.